

CUA-RSIBench


面向真实软件操作的可验证改进基准

真实应用 · 真实来源数据 · 独立验收 · 可审计训练评测链

摘要

本项目借鉴 RSIBench-Data 的固定服务边界，把研究对象扩展到 computer use。当前实现以原生 Kanboard 为环境，用公开 issue 元数据构造可重置任务，并通过应用数据库回读验证结果。模型可见页面文字和控件，不能直接调用数据库、文件或应用 API。

我们分别记录环境执行、训练服务与任务能力证据。Tinker、E2B、Harbor 的真实服务链已完成一次端到端评测；微量训练后的目标模型在用于链路贯通的合成浏览器任务中得分为 0。这是有效的负结果，不应写成训练成功率或自我改进成果。正式提升结论仍需通过难度校准、对照实验和独立测试。



固定服务与评测边界；研究者只改变允许的数据策略。

保留每次尝试、历史最佳与失败证据；最终测试不参与选择。

图 1 数据研究轨道的目标协议。训练与采样分离，Harbor 调度实际任务，独立验收提供选择依据。机制图不等同于完整多轮改进实验已完成。

本报告状态

这是方法与试验性证据报告，不是成熟排行榜，也不声称已证明持续 RSI。公开代码和证据用于复核及后续扩展。此前全满分的简化任务已降为冒烟测试。

代码与复现材料：github.com/nanobanana123/cua-rsibench

真实环境与操作边界

正式方向采用未改写业务界面的 Kanboard 1.2.54。PHP 控制器、原生登录、项目、任务、评论、表单提交与 SQLite 持久化均来自真实应用。每次试验创建独立 E2B 环境并注入初始状态，试验结束销毁。




图 2 实际 E2B 中的 Kanboard 原生任务列表。公开 issue 的标题和引用编号进入真实应用，模型需要进一步打开各条记录核对来源字段。

角色	权限与责任
被测模型	仅当前可见 DOM 文字与控件；点击、输入、选择、有限按键、返回。
评测主控	创建环境、注入数据、记录截图、抓取独立数据库快照。
Verifier	验证目标字段及无关对象完整性，不接受模型自报完成。

范围限制：当前是 DOM 辅助的浏览器操作，尚不代表纯截图定位、完整 Windows/macOS 桌面或跨应用企业部署。

真实数据与构造规则分开

本次快照包含 37 条真实公开 issue 元数据，来自 kanboard/kanboard。采集时间为 2026-09-23T00:19:37.276675+00:00。排除 pull request、作者信息与正文，仅保留复核所需字段；每条记录都有来源 URL。

数据类型	来源与处理
真实字段	issue 编号、标题、状态、创建/更新时间、关闭时间、标签、评论数、来源链接。
变换	标题最多保留 24 个词；不复制 issue 正文、评论正文、邮箱和作者画像。
构造字段	本地项目名、负责人、SLA 或排期规则、历史副本干扰项。明确标注为 benchmark constructs。
复现标识	采集时间、元数据 SHA-256、应用版本、初始状态与 verifier 版本。

样例来源

GitHub issue #5895 · open · updated 2026-09-04T07:11:32Z

GitHub issue #5894 · open · updated 2026-09-21T04:52:23Z

GitHub issue #5893 · open · updated 2026-08-30T14:08:38Z

数据真实并不自动意味着任务真实。任务指令需要合理的业务目的，操作链需要使用应用原有行为，答案则应来自可独立计算的规则。报告不把合成的分派政策冒充上游维护者的实际决策。

污染与拆分

公开元数据可能已被模型见过，因此只能支持流程执行与规则遵循评估。正式数据研究需把训练、验收和最终测试按源 issue 与任务模板隔离，禁止把测试轨迹转成训练记录。当前校准集不被称作封闭测试集。

用区分度选择任务

层级	业务任务	主要难点
L1	明确单对象修改	定位真实控件，提交并回读。
L2	公开 backlog 排序与分派	跨任务读取真实状态和时间戳；排序选择；保留其他项目。
L2+	批准版本驱动的事件升级	区分原始导入、旧批准版本和新草稿；联合条件判断。
L3	预算与依赖约束下的排期	多个容量约束、依赖与互斥关系；全局可行性及并列规则。

校准原则

先用 Astra 与 Sol 的固定配置试跑，保留成功、失败、部分完成、步骤及服务异常。若所有模型几乎全对，该组任务只适合冒烟或回归；若失败主要来自接口或环境故障，则修复基础设施后再评估难度。

不能通过故意损坏环境、缩短到不合理的步数预算，或者隐藏必要信息来制造低分。每个任务必须有可执行的独立解法。较难的任务应来自真实约束组合、信息分散、状态恢复和长流程，而非单纯增加点击数量。

正式指标

主指标为严格任务成功率，辅以逐字段完成率、未授权副作用、步骤、token、时延与基础设施失败率。不同难度和应用类型分别报告。单次执行的差异不足以宣布模型排名。

当前状态：饱和的手写页面实验已停止并保存原始记录；原生 Kanboard 与真实元数据任务用于新一轮难度校准。

独立验证与失败分类

验证依赖最终保存状态，而不是页面看起来正确或模型说已完成。Kanboard 试验比较开始和结束时的任务、评论、项目、用户角色等快照。目标字段根据固定指令重算，其余对象必须保持语义完整。

检查	可拒绝的错误
目标对象	相似项目/重复引用导致改错任务，漏改负责人、优先级或复杂度。
无关状态	误改归档项目、删除任务、更改源描述或评论。
持久化	仅填写未保存、遗漏确认、页面表象与实际保存状态不一致。
等价归一化	仅归一化应用维护时间戳、空工时与 0、原生文本框的 LF/CRLF 换行；不忽略内容变动。
基础设施	API 超时、沙箱创建失败或网络中断独立记录，不视作能力得分 0。

隔离模型

被测策略是远程 API 模型，只拥有受限 GUI 动作通道，不能读取主控文件。Harbor 的 separate verifier 在另一环境运行，答案不放入 agent 环境构建目录。本地回归 fixture 中的公开答案不被称为隐藏集。

完整性证据

请求、响应摘要、环境版本、任务哈希、候选父子关系和接受/拒绝理由共同构成证据。哈希链能揭示日志被修改，但同机哈希链不等同于对恶意主控的安全隔离。

真实训练与云端评测结果

阶段	已核验结果
Tinker 训练	Qwen/Qwen3.5-4B ; rank 8 ; 1 步更新 ; 6 条训练记录 ; 本轮计划 1220 token。
Checkpoint	保存 sampler weights , 并从该 checkpoint 实际采样。公开摘要仅记录 checkpoint 哈希。
E2B 代理	带临时 Bearer 鉴权的采样服务 ; 任务完成后销毁代理沙箱。
Harbor 合成任务	完成 1 个任务 ; 0 个基础设施错误 ; 独立 verifier reward=0.0。

Oracle 可解性验证		100%
微量训练 checkpoint		0%

图 3 云端集成验证。两条柱状值来自不同角色的冒烟执行，不是模型对比，也不是训练前后提升。Oracle 得分 1 表明任务可完成，目标 checkpoint 的 0 分是被测行为失败。

这次训练仅验证真实权重更新与执行链，不支持学习效果结论。后续必须固定目标模型、数据接口、评测超参数和预算，以更多行为对齐的示范及独立任务检验改进。美元费用暂为 Unknown，不能按 0 元报告。

原生界面校准记录

运行	模型	步数	严格结果
basic-51	5.6-sol	8	通过
public-allocation-51	6-astra	49	未通过
public-allocation-51	5.6-sol	47	通过
public-51	5.6-sol	59	通过

另有 7 条基础设施失败记录，保留但不作为模型失败计分。单次校准结果只支持该配置下的执行证据，不能推广为模型能力排名。

排期失败的具体原因

Astra 找到了可行且总价值最优的组合（价值 49），但成本为 62；符合第二层最小成本规则的方案成本为 52。严格评分因此未通过。这是条件优先级和验收完整性问题，不是网络错误。规划成本是明确构造的任务输入，并非真实上游项目预算。

为什么不继续报告先前的 +14.29 分

旧版本的差值来自预写规则在少量 JSON fixture 上的切换，没有模型提出候选，也没有真实 UI 或隔离的隐藏集。它已明确降为回归测试结果，不能作为 RSI 提升。

后续实验准入

只有通过环境重置、独立解法、负例验证、数据隔离和难度校准的任务才进入正式实验。正式结果还需重复运行、报告不确定性，并保留失败尝试与预算开销。

改进实验应如何运行

两类更新对象分别报告

Harness 轨道冻结模型权重，只允许更新注册的策略与工作流。Data 轨道冻结训练和评测服务，只改变新训练数据及允许范围内的配置。Astra/Sol 可担任研究或执行角色；它们不是本次 Tinker LoRA 训练目标。

每轮流程

从当前已接受版本出发，运行训练任务，分析失败轨迹，产生带假设的候选；在独立验收任务上检查严格提升及逐题回归，接受后继承，拒绝则保留父版本。搜索结束并冻结最终选择后，才运行隐藏测试。

对照与统计

至少比较冻结基线与相同预算的非递归搜索；记录最佳、最后与实际继承的版本，避免把测试集最高分用于选择。按任务族报告配对结果和多次执行，不把重复运行同一确定性规则当作独立模型采样。

不提前声称实现

已实现的服务连通性、试验运行器和 schema 不是持续自我改进的证明。完整正式实验仍需在通过校准的真实软件任务上运行，并审计每一条结论。若改进为零或出现回归，报告必须保留该结果。

复现、来源与限制

[1] RSIBench-Data: Benchmarking Data-Centric Research for Recursive Self-Improvement
<https://arxiv.org/abs/2607.25886>

[2] RSIBench-Data reference implementation
<https://github.com/evolvent-ai/RSIBench-Data>

[3] Kanboard source and release v1.2.54
<https://github.com/kanboard/kanboard/releases/tag/v1.2.54>

[4] Harbor documentation
<https://docs.harborframework.com/>

[5] Tinker Python SDK
<https://github.com/thinking-machines-lab/tinker>

[6] E2B sandbox SDK
<https://github.com/e2b-dev/E2B>

[7] CUA-RSIBench source, evidence and reproduction
<https://github.com/nanobanana123/cua-rsibench>

复现范围

代码包含任务包、应用初始化、GUI runner、训练后端、云端代理、Harbor adapter 和独立 verifier。需要自行配置提供商凭据；任何 API key、账号私有配置或完整提供商响应都不属于公开产物。

当前不能从结果推出的结论

不能证明在未见过的应用中泛化，不能证明对 Windows/macOS 的完整控制，不能证明连续多轮模型自我提升，也不能从小样本决定 Astra/Sol 的总体排名。公开源数据、模型别名、默认服务配置与不可确认的费用均保留各自限制。

报告数据来自 outputs/evidence.json。字段为 null 表示未取得可靠证据；试验性任务结果不等同于正式发布的榜单。